BenchmarkFactory 面向智能体韧性测试闭环的机制驱动评测基准

摘要

智能体自主执行韧性测试，需要具备风险发现、场景设计、故障注入、根因诊断及修复验证的完整闭环能力，但现有评测多聚焦于事故诊断或提供预设场景，难以公平比较不同智能体在主动测试全流程的表现。本文提出 BenchmarkFactory，一个机制驱动的韧性测试闭环评测基准。围绕检测、抑制、隔离、转移和恢复五类能力，设计独立于被测智能体的真值构建与裁决过程，通过程序枚举候选对象与模型语义核查结合，生成位置级风险标注及场景有效性判据。设计发现定位、执行恢复和诊断修复三类任务，支持自主闭环与标准输入两种模式，区分业务主故障与智能体运行扰动的双层记录。三个主要研究问题关注不同智能体及模型配置的闭环完成能力差异、能力瓶颈所在阶段，以及信息变化与运行扰动对执行稳定性的影响。贡献在于机制约束的独立真值构建方法、统一的跨系统任务协议，以及固定分母、同题配对和真实暴露的可执行实验设计，为比较智能体韧性测试能力提供了系统化框架。

关键词：智能体评测；韧性测试；混沌工程；机制驱动真值；闭环任务协议

1 引言

智能体在软件运维与测试中的应用日益广泛，但其主动测试能力难以比较。已有评测多聚焦事故诊断、根因分析或缓解任务[1][2][4]，或提供预设场景检验执行可靠性[5]，而主动韧性测试要求智能体从系统材料中发现潜在风险、自主设计验证场景、执行故障注入实验、诊断薄弱机制并验证修复效果的完整闭环能力。不同智能体可能使用不同模型、工具集和策略，若仅依赖自选样本的成功率或孤立阶段指标，难以识别能力瓶颈出现在发现、设计、执行还是恢复环节，也无法公平比较跨原生系统的表现。

本文提出 BenchmarkFactory，一个面向智能体韧性测试闭环的机制驱动评测基准。围绕三个主要研究问题展开：**RQ1** 不同智能体及模型配置完成韧性测试闭环的能力有何差异？**RQ2** 能力瓶颈出现在哪些阶段（发现、设计、执行、诊断、修复）？**RQ3** 信息变化与运行扰动如何影响执行稳定性和自主恢复？这些问题的回答依赖统一的真值标准、标准化任务协议和可控实验设计。

本文的贡献包括：(1) 机制约束的独立真值构建方法，通过程序枚举对象与模型语义核查结合，生成位置级风险标注及场景有效性判据，支持服务级与位置级去重的定位评价；(2) 发现定位、执行恢复和诊断修复的统一任务协议，区分自主闭环与标准输入模式，分别记录业务主故障与智能体运行扰动，提供标准阶段输入以隔离上游差异；(3) 固定分母、同题配对和真实暴露的可执行实验设计，明确实验单位、样本量、预算冻结、重复次数及失效处理规则，支持配对差异分析与效果大小估计。

2 背景与定位

韧性机制与风险定义 韧性测试检验系统在故障下的保护机制有效性。本文考虑五类韧性能力及其保护机制：(1) 健康探针，定期检测组件可用性；(2) 抑制机制，包括超时、重试、熔断、限流与过载保护；(3) 隔离机制，包括资源隔离与舱壁、异步消息解耦；(4) 转移机制，包括多实例冗余、副本故障域分布与故障切换；(5) 恢复机制，包括自动恢复、状态持久化与恢复。重试、任务取消和分布式错误处理研究说明，保护逻辑本身需要验证[6][7][8]。本文将风险定义为适用保护机制缺失或失效：机制缺失需依据业务与系统契约的适用性证据，而失效指在固定条件下未满足预期健康谓词。本文使用固定条件检验机制有效性，不搜索参数失效边界或阈值最优点。

业务韧性与执行韧性 业务系统本身的韧性（架构设计、配置质量、故障域分布）[9]与智能体执行韧性测试任务时的韧性（工具稳定性、信息完整性、自主恢复能力）是不同层面的问题。本研究将两者分开：被测业务系统作为实验环境，其韧性质量影响真值分布，比较时通过同版任务和状态初始化控制这一因素；智能体面对运行扰动的稳定性和恢复能力则通过额外扰动层独立记录。

混沌工程与主动测试 混沌实验通过施加有界故障检验系统假设，已有工作[3]实现了假设生成、场景设计、故障注入观测、分析改进与重放的自动混沌工程闭环。运维事故诊断任务[1][2][4]提供故障后的遥测数据及根因注释，关注诊断准确性与终态一致性。本文定位为比较不同智能体自主完成主动韧性测试全流程的能力，统一机制约束真值、场景有效性三门标准、主故障与额外扰动的独立记录，提供不同于构建单个混沌智能体的系统化评测框架。

3 问题形式化与任务协议

3.1 被测对象与实验单位

本研究的评测目标是智能体执行韧性测试任务的能力。被测配置由智能体实现、底层模型及其参数设置组成。智能体实现包括 BladeAI、Claude Code、Codex 和 DeepSeek Harness 等候选系统。轨道 A 固定 BladeAI 并改变其底层模型，轨道 B 保留各系统原生编排。底层模型指实际响应用户请求的语言模型，例如 Qwen 系列、Opus 系列、GPT 系列或 DeepSeek 系列。每个被测配置在实验中保持固定的工具语义、权限范围、系统快照、负载条件及预算分配。

业务系统与智能体韧性属于两个分析层次。业务系统是实验环境，其自身韧性机制的有无或强弱是观测对象；智能体韧性指智能体在信息变化和运行扰动下维持任务执行和自主恢复的能力。本研究评估智能体面对业务系统韧性问题及环境扰动时的表现，而非业务系统本身的韧性水平。

实验以 campaign 为顶层单位，一次 campaign 对应一个被测配置在一个目标业务系统上的完整扫描与测试过程。episode 是固定场景在一次初始化状态下的独立任务运行，执行类 episode 包含注入、观测

与恢复，诊断类 episode 从统一证据起点运行。一个 episode 可观测一个或多个位置；共享注入或修复的观测按独立实验组记录。每个 campaign 可产生若干 episode。

位置粒度定义为三元组（逻辑调用或配置或部署对象、风险语义、必要上下文）。逻辑调用指代码中的服务调用点或依赖访问点，配置对象包括超时参数、重试策略、资源限制等设置，部署对象包括容器、Pod 或节点等运行实体。风险语义指该位置缺失或失效的韧性机制类型。必要上下文包括该位置的调用路径、配置作用域或部署拓扑关系。位置不按临时 Pod 数量计数，而按逻辑对象与风险语义的独特组合计数。

3.2 故障与扰动

主故障是验证韧性机制有效性的核心条件变化，由实验平台的故障注入执行器施加。八类主故障分别为请求挂起、固定错误响应、成功提交后响应丢失、依赖访问中断、就绪条件失效、进程/容器/Pod 退出或挂起、节点故障域隔离和受控资源压力。成功提交后响应丢失关注业务已提交而调用方未收到响应的状态；就绪条件失效关注不能承接流量时的判定与摘流行为。

不同故障类型与韧性机制之间不存在一一对应关系。例如，请求挂起适于观察调用方的等待终止行为，持续固定错误适于观察满足触发阈值后的熔断行为；两者不能只因均为下游异常而互换。具体故障的施加范围受本版执行器支持的技术手段和测试副本的隔离边界约束。参数按有效配置和触发条件预先校准并冻结，变体验证针对有限的离散预注册集合，而非边界搜索或阈值优化任务。

额外扰动是在标准执行流程之上引入的信息变化或运行约束变化，用于测试智能体在非理想条件下的鲁棒性。扰动类型包括：目标对象标识漂移（如 Pod 替换导致 UID 变化）、配额缩减（如测试命名空间的 ResourceQuota 临时减少）、遥测接口异常（如监控 API 返回 503 或超时）、关键指标数据缺口（如时间序列不连续）、主故障强度偏差（如注入时长或错误率与计划值偏离）、基线行为漂移（如正常流量模式变化）、安全阈值压力（如并发连接数接近上限）、清理延迟（如清理 API 应答延迟）。

扰动与主故障在授权和记录上分开处理。主故障的清理由 episode 生命周期管理，扰动的清理由独立的环境稳定化流程处理。Ground Truth 参考无额外扰动的执行条件，扰动现象不得直接反写到原始 Ground Truth 中。扰动触发以语义事件或等价工具能力为准，不要求不同智能体在第 N 次同名调用时触发。信息结构变换（如 JSON 字段重排序）作为保语义输入变体单独分组；运行约束的实际变化则标记为运行扰动，两者分别分析。

3.3 任务协议

3.3.1 任务一：风险发现与场景设计

任务一要求智能体从初始只读材料中识别韧性风险位置并设计可执行的验证场景。输入材料包括业务系统的源代码、配置文件、Kubernetes 清单、架构图及可选的分布式追踪样本。智能体需输出风险位置列表，每个位置关联服务名称、机制类型、风险描述、故障类型、触发前提及观测目标。

场景三门分别裁决为通过、明确设计错误或证据不足；证据不足单列，仅全部通过的场景计入有效场景数。场景设计必须明确三要素：可执行性（故障类型及参数可由执行器实现）、可触发性（触发前提如负载条件或状态前置在测试环境中可满足）、机制判据正确性（期望的健康行为与观测窗口符合该机制的设计契约）。参考执行器仅负责执行已设计的方案，不能替代智能体完成关键设计决策。同一故障大类（如"下游错误"）下的不同具体故障不能自动继承设计有效性，必须针对具体机制重新设计判据。

智能体在首次故障注入前必须封存初始计划。封存后，智能体可在预算范围内根据工具返回的证据自我纠正或补充发现，最终的闭环能力可提高，但初始任务一的成绩不得事后填补。controller 按公开的动作语义、预算约束和作用域规则执行智能体的请求，不依赖 Ground Truth 的正确性在线放行或阻止操作。独立的 evaluator 在 episode 结束后判定得分。

3.3.2 任务二：执行验证与恢复

任务二要求智能体执行已设计的场景、验证机制行为并完成自主恢复。完整成功的 episode 包括：故障实际生效且触发前提成立、按规定观测目标收集证据、诚实判断机制行为是否符合预期、自主撤销故障、业务状态恢复到可接受状态。

机制行为判定以动态 Oracle 为准，阴性结果（机制正常工作）与阳性结果（机制失效）均可构成成功完成的实验。工具返回的操作确认（如 API ACK）不等同于实际效果，智能体需通过后续观测验证。智能体自行设置的有界自动到期机制可计入自主恢复，由 controller 托底的环境收敛仅算环境收敛，不计入智能体的自主恢复能力。

故障未生效对 Ground Truth 可能导致该位置判定为未决，但对执行任务而言，如果故障未生效是由于智能体的设计错误或操作失误，仍判定该 episode 失败。正常情况下可执行的场景因智能体合理判断中止（如发现前提条件不满足）仍记为未完成；预设应中止的场景（如故意设置的无效配置）若智能体正确决策中止，可判决策正确但单独列示，不计入完成注入的统计。平台原生的 fixture 失效（标记为 CASE_INVALID）与智能体操作导致的失效分开处理。

3.3.3 任务三：诊断与修复

任务三分为诊断子任务和修复子任务。诊断要求智能体根据统一提供的证据和初始缺陷状态，识别薄弱的组件、机制类型及根本原因，并提供证据支持的因果链。诊断输出不要求唯一的措辞表述，但必须在语义上指向正确的技术对象和因果关系。

修复子任务针对固定的可修复集合G_{fix}进行。可修复集合由实验设计预先定义，不要求所有发现的风险均可修复。修复要求智能体在资源预算内生成并验证修复方案。验收契约包括：通过同故障重放验证机制行为恢复到健康状态、正常业务流量和数据保留不受破坏、修复操作在规定的资源预算内完成。验证器按逻辑目标重新绑定观测对象，旧 Pod 消失不自动视为修复成功。

修复方案可引入合理的冗余、副本或降级策略，但不接受停止负载、禁用功能、删除监控或重写验收标准的方案。例如，针对调用方超时缺失的修复，可以是在代码或配置中添加有效的 deadline 绑定，验证通过重放确认：在挂起目标 RPC 时，调用方在规定时限内终止请求并采取适当的后续行为。此处的示例描述基于设计预期，非实际测量结果。

3.4 执行模式

自主闭环模式在一次 campaign 内衔接三项任务，以上述封存计划为起点，记录自主发现至验证、诊断和恢复的全过程。每个逻辑风险的所有尝试计入预算与成本，评价器不在线提示答案。

标准输入模式用于隔离上游任务的差异，聚焦特定阶段的能力。任务一的标准输入为统一的只读项目资料；任务二的标准输入为相同的已验证场景及观测目标，隐藏该位置的阳性或阴性判定及根本原因；任务三的标准输入为统一的证据集合和场景初始状态，智能体可进行同等范围的只读追查。标准输入隔离了上游差异，其成功率不能与自主模式中智能体自选样本的成功率合并到同一分母进行拼接，也不要求所有智能体与所有场景的交叉组合矩阵。

4 机制驱动的 Ground Truth 工厂

4.1 规则卡与机制覆盖

Ground Truth 工厂以规则卡驱动，每张规则卡定义一类韧性机制在特定条件下的预期行为。规则卡包含八个字段：适用条件（如"存在外部依赖调用"）、观测对象（如"调用方进程或配置"）、保护证据（如"超时参数显式设置"）、固定故障（如"依赖挂起"）、触发前提（如"负载到达或状态已就绪"）、健康谓词（如"请求在 deadline 内终止"）、观测窗口（如"覆盖已配置的探针周期、失败阈值及摘流完成时间"）、恢复条件（如"故障撤销后无残留错误且业务状态一致"）。

本研究的机制范围覆盖五类能力：检测、抑制、隔离、转移、恢复。每类能力下包含若干机制，初步设计草案共 13 个机制和 25 条规则。表 1 列出各机制及其草案规则数量。需强调的是，表 1 中的数

字为设计覆盖范围，而非已验证完成的规则数量。实际验证过程中，部分规则可能因材料不足、前提条件复杂或执行器限制而处于未决状态。

表 1 韧性机制覆盖范围（草案规则数量）

能力类别	机制	规则数
检测	健康探针（就绪探针、存活探针）	2
抑制	超时控制、重试与退避、熔断器、限流、过载保护	10
隔离	资源隔离与舱壁、异步消息解耦	3
转移	多实例冗余、副本故障域分布、故障切换	5
恢复	自动恢复、状态持久化与恢复	5

4.2 对象枚举与语义复核

Ground Truth 构建从规定材料中枚举可能的观测对象开始。规定材料包括业务系统的源代码、配置文件、Kubernetes 清单和可选的分布式追踪样本。程序化扫描从代码中提取服务调用点、异常处理块、资源访问语句，从配置中提取超时参数、重试策略、资源限制，从 Kubernetes 清单中提取健康探针、副本数、节点亲和性，从分布式追踪中提取调用链路和延迟分布。多个来源的扫描结果取并集，形成候选对象集合。

扫描产物仅为候选，字段未显式出现不等同于保护缺失。例如，某个 HTTP 客户端调用未显式设置超时参数，但该客户端库可能有默认超时，或上层框架已统一配置超时策略。静态扫描无法证明风险一定存在，需结合动态证据和语义推理。模型执行语义复核，检查候选对象是否满足规则卡的适用条件和保护证据要求。

适用性判断依赖业务契约和系统架构。例如，调用方超时规则需外部依赖调用及有界等待契约；多实例冗余需可用性目标和业务状态语义支持相应的冗余方式。保护证据可能来自代码、配置、框架行为或运维惯例。显式代码（如 `context.WithTimeout`）是直接证据，框架默认行为（如某些 RPC 库的内置超时）是间接证据，需额外验证。多源对照和抽样检查可提高置信度,但不能证明候选集合的完备性。静态分析无风险证据不等同于不需要保护,必须结合适用性条件和动态观测综合判断。

4.3 动态 Oracle 与三值判定

动态 Oracle 在 episode 执行后判定机制行为。判定依赖三个前提的验证：故障 D 实际生效、适用性 A 和触发前提成立、健康谓词 H 的观测结果。D 通过执行器日志和目标对象状态确认,例如目标 RPC 在注入窗口内持续未返回，或目标进程退出已由独立状态观测确认。A 通过负载到达、状态前置或配置

激活确认,例如调用方在观测窗口内实际发起了至少一次对目标依赖的请求。H 通过观测窗口内的行为证据判定,例如请求在规定时限内终止、探针失败后 Pod 从端点列表移除、熔断器打开后拒绝新请求。

判定规则为：当 D 确认且 A 确认且证据充分时,若违反 H 则判定为阳性（机制失效）,若满足 H 则判定为阴性（机制正常）；若 D 或 A 不成立,或证据或窗口不足以验证 H,则判定为未决。阳性对应已满足测试前提下的健康谓词违例，阴性对应有效测试下健康谓词成立。

调用方超时与下游后台取消是不同的观测对象。调用方超时关注调用方进程是否在 deadline 内终止请求并释放资源,下游取消关注下游服务是否收到取消信号并停止处理。两者可能同时满足、部分满足或均不满足,需分别观测和判定。

状态持久化的触发前提可能包括故障前写入确认（ACK）。例如,某服务在处理请求时先写数据库并等待 ACK,然后返回响应。若规则要求验证"故障后从持久化状态恢复",则触发前提为"故障注入前至少一次写入已获得 ACK"。没有 ACK 的写入不构成有效的持久化前提。并非所有规则都要求分布式追踪流量,例如资源隔离规则可通过资源配额静态配置和运行时资源使用指标验证。

观测窗口依据 deadline、探针周期、退避策略或恢复契约确定,不采用固定的十分钟判定失败。窗口必须足够长以观测完整的机制行为,例如重试次数规则需覆盖契约规定的完整尝试序列；熔断器的打开、半开和关闭是否全部必需，取决于该规则的健康谓词。满足完整谓词后停止观测,不因单一动作（如容器重启）即判定健康。业务 SLO 影响（如响应时间增加）单独记录,但不是机制缺陷成立的必要条件或充分证据。机制失效指保护行为缺失或错误,即使业务最终通过其他途径恢复。

恢复判定需故障残留与业务状态的证据。故障撤销后,需确认目标对象恢复正常状态（如 Pod 重新进入 Ready）、故障残留已消除、业务流量满足冻结的恢复契约、关键数据一致性检查通过。仅凭 API 操作返回的 ACK 不能判定恢复成功,必须通过后续观测验证实际效果。

4.4 位置分组与继承

位置分组用于节约实验成本,在保持 Ground Truth 位置分母不变的前提下,减少实际执行的 episode 数量。分组不减少 Ground Truth 中的位置计数,仅在实验执行时合并观测。

共享下游依赖、使用同一客户端实例或引用同一 ConfigMap 不是分组的充分条件。有效分组要求多个位置的保护逻辑相同、覆盖路径相同、触发前提一致且无位置级配置覆盖。例如,两个服务调用同一下游 API,若它们使用相同的客户端库和超时配置,且调用路径无差异,则超时机制可分组验证。若其中一个服务在代码中覆盖了超时参数,或调用路径经过不同的中间件,则不可分组。

一次故障注入可分别观测多个位置。例如,注入下游服务的挂起故障后,可同时观测多个调用方的超时行为。若所有调用方的超时配置和行为结构等价且证据充分,可继承判定结果。若调用方之间存在差异（如超时时长不同、重试策略不同）,则需拆分为独立的观测组或判定为未决。

继承判定需区分直接观测（direct）和推断继承（inferred）。直接观测指在该 episode 中实际收集了该位置的行为证据,推断继承指基于结构等价性从其他位置继承判定结果。报告 Ground Truth 时,需明确标注每个位置的判定来源,并记录独立实验组的数量,避免将相关位置当作独立样本进行统计分析。

每份报告的命中范围由明确列出或界定的风险位置集合决定。报告位置 A 仅覆盖 A；覆盖 B、C 需有对应对象与上下文及可继承关系的证据。评价按该覆盖集合计算位置命中，其余位置保持各自的判定状态。

5 评价与指标

5.1 位置层计分与去重

Ground Truth 以位置粒度为主计分单位。每个位置对应三元组（逻辑对象、风险语义、必要上下文），分别判定为阳性、阴性或未决。服务判断层按（service、mechanism、风险语义）去重，作为辅助分析，用于解释能力瓶颈的分布特征，不替代位置层的覆盖计算。

智能体的输出在已裁决的 Ground Truth 范围内判定为真阳性（TP）、假阳性（FP）或未决（U）。真阳性指智能体正确识别的阳性位置，假阳性指智能体报告但经裁决为阴性或不存在的位置，未决指智能体报告但 Ground Truth 判定证据不足的位置。已裁决报告数为$N=TP+FP$，裁决覆盖率为$N/(N+U)$，二者均不随场景有效性减少。令$|G|$为同版本 Ground Truth 中的阳性位置总数。

定位精确率$P_{loc}=\frac{TP}{N}$，定位召回率$R_{loc}=\frac{TP}{|G|}$，定位 F1 值$F_{1,loc}=\frac{2TP}{|G|+N}$。未决位置不计入误报，已裁决精确率报告时须同时报告已裁决数N和裁决覆盖率。可报告精确率下界$\frac{TP}{N+U}$和上界$\frac{TP+U}{N+U}$，但若 Ground Truth 尚可扩充，召回率及其导出指标不能假定固定区间，需标注分数为暂定。分母为零的条件率记为 NA，并同时报告计数；当$|G|>0$且没有报告时，两种 F1 均为零。

场景有效性在真阳性子集上判定。令J为TP中至少一个场景通过三门（可执行、可触发、机制判据正确）的位置数。条件场景率$\frac{J}{TP}$衡量真阳性位置中设计有效的比例。联合精确率$P_{joint}=\frac{J}{N}$，联合召回率$R_{joint}=\frac{J}{|G|}$，联合 F1 值$F_{1,joint}=\frac{2J}{|G|+N}$。$N$为已裁决报告数，与有效场景数$J$分别计数。

示例：某智能体在$|G|=10$的阳性位置集合中输出 8 个位置，经裁决$TP=6$、$FP=2$，其中$J=5$个位置至少有一个有效场景。则$N=8$，定位精确率$P_{loc}=6/8=75.0\%$，定位召回率$R_{loc}=6/10=60.0\%$，$F_{1,loc}=2\times6/(10+8)=66.7\%$。条件场景率$5/6=83.3\%$。联合精确率$P_{joint}=5/8=62.5\%$，联合召回率$R_{joint}=5/10=50.0\%$，$F_{1,joint}=2\times5/(10+8)=55.6\%$。若初始阶段智能体未输出任何场景，则$J=0$，但真实的$TP$不抹除，定位指标保持不变，联合指标为零。

5.2 Ground Truth 扩充与新发现

智能体在 Ground Truth 范围外的输出需独立复核。同批次输出先封存全部配置及重复结果，然后由独立复核者取并集。复核确认为真阳性的新位置补充到扩展 Ground Truth G^* 中，冻结后统一重算全部智能体在新范围内的指标。过程中不得泄露新题答案，跨批次更新 Ground Truth 时按版本分开统计，不得混合版本计算成绩。证据不足的报告保留为未决，裁决覆盖与已确认结果同时报告。

真实新发现计入 TP，且若智能体为其设计了有效场景，亦计入 J。新发现按独立的修复组单独报告新位置数和新机制类型数，不叠加任意系数作为奖励。新发现的场景有效性依据该智能体封存的方案判定。

5.3 任务阶段与执行判定

任务二的成功要求故障实际生效、触发前提成立、规定观测完成、诚实判断、自主撤销故障及业务状态恢复。机制阴性与阳性均可成功完成实验。正常可执行场景因合理判断中止仍记为未完成；预置的应中止场景（如故意无效配置）若智能体正确决策中止，可判决策正确但单独列示，不计入完成注入统计。平台原生 fixture 失效标记为 CASE_INVALID，与智能体操作导致的失败分开处理。

任务三的诊断子任务要求识别薄弱组件、机制及根本原因并提供证据支持的因果链，输出不要求唯一措辞但需语义正确。阴性题的正确结论是证据支持该规则的健康谓词成立，并说明所观测机制与适用范围。自主修复闭环以固定的可修复位置集合 G_{fix} 为分母；标准修复成功率则以固定分配的可修复试验总数为分母，包括未尝试和未完成的试验。未发现或未尝试的位置保留在整体分母中，但不重复计入下游独立能力的零分。

5.4 核心自主与效率指标

核心自主能力 $K_{core}/|G|$ 要求同一智能体在同次 campaign 内完成发现定位、有效验证、正确诊断、自主恢复的全链路。修复闭环 $K_{fix}/|G_{fix}|$ 在可修复子集上额外要求有效修复通过验收。初始阶段指标、标准阶段指标与自主漏斗分别在对应的固定样本集合上计算。安全越界保留失败，不排除分母，不被加权抵消，不拼接任意大加权分数。

效率指标包括原始时长、工具调用次数、token 消耗及计算成本。报告总资源与成功数，不在小组内归一化或按最小最大值缩放。

5.5 稳定性与重复指标

pass@k 为 k 次重复中至少一次成功的比例，pass^k 为 k 次重复全部成功的比例。pass@1 表示单次执行成功率。逐题报告 5 次重复的成功次数，以区分偶发完成与稳定完成。

表 2 核心评价指标体系

指标类别	指标	定义	备注
定位	P_{loc}	TP/N	已裁决精确率
	R_{loc}	$TP/\lvert G\rvert$	定位召回率
	$F_{1,loc}$	$2TP/(\lvert G\rvert+N)$	定位 F1
联合	P_{joint}	J/N	联合精确率
	R_{joint}	$J/\lvert G\rvert$	联合召回率
	$F_{1,joint}$	$2J/(\lvert G\rvert+N)$	联合 F1
自主	$K_{core}/\lvert G\rvert$	全链路完成率	同次 campaign
	$K_{fix}/\lvert G_{fix}\rvert$	修复闭环完成率	固定可修复集合
稳定性	pass@k	至少一次成功	k次重复
	pass^k	全部成功	k次重复

6 原型结构与实现边界

评测原型已有任务层公开与内部 Episode、隐藏 GT 的 schema 契约，以及用于候选模型管理和双轨比较的 harness 结构。`resilience_agent` 文档描述 12 类语义扫描候选及一匹配一 Episode 的编译路径；该实现范围与表 1 的 13 机制、25 条草案规则分别记录。`evaluator/evaluator.py` 检查独立证据来源、稳定引用和 required gates，缺少必需证据或证据不合规时判为 INCONCLUSIVE，并按契约折叠主状态。`disturbances/`保存扰动类型库与事件证据约定。

完整评测以第 3—5 节的任务、D/A/H 和计分协议为冻结契约；规则覆盖、故障能力及候选配置经资格检查后进入正式矩阵。现有 gate 折叠器消费独立证据，不承担生成因果真值的职责；原型模块的存在也不等同于全部规则或候选应用已经通过运行验证。

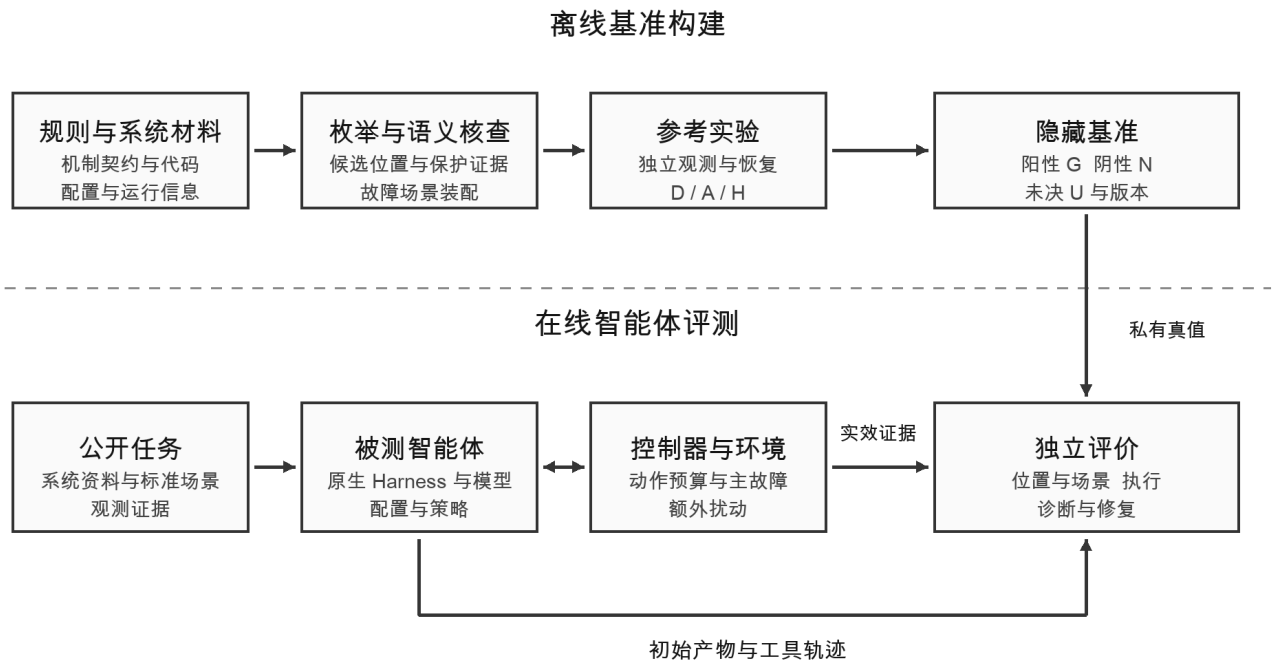


图 1 机制驱动的基准构建与独立智能体评价架构

7 实验设计

7.1 研究问题与变量

RQ1 不同智能体及模型配置完成韧性测试闭环的能力有何差异？轨道 A 固定 BladeAI 智能体并替换底层模型，轨道 B 保留各原生智能体系统的编排与模型绑定。两轨分别报告核心闭环能力、联合定位场景能力及标准任务成功率。

RQ2 能力瓶颈出现在哪些阶段？分析风险发现、场景设计、执行观测、诊断及修复五个阶段。标准输入模式隔离上游差异，自主漏斗展示完整链路的累积衰减。使用标准输入结果解释自主失败，不仅比较各智能体成功走到下游阶段的自选样本。

RQ3 信息变化与运行扰动如何影响执行稳定性和自主恢复？在标准任务二中，同题同种子条件下配对无扰动与有扰动执行，报告配对成功率差、扰动实际暴露率及处理率。

7.2 被测配置与资格化

候选业务应用为 OTel Demo、Sock Shop、Train Ticket，均需在 Kubernetes 测试集群中完成部署并通过资格检查后纳入实验。资格检查包括健康探针就绪、基线负载稳定、规则所需观测证据可获得、执行器故障实际生效。

候选智能体包括 BladeAI、Claude Code、Codex 及 DeepSeek Harness。轨道 A 固定 BladeAI 并替换底层模型，候选模型包括 Qwen 系列、Opus 系列、GPT 系列及 DeepSeek 系列的具体版本，实际名称与

版本在资格化清单中冻结，支持性由资格检查决定。轨道 B 每种原生智能体冻结其可用配置，不强制要求全部组合。注册表仅用于管理候选配置。固定工具语义与权限、系统快照、负载条件、预算分配及软件版本。

7.3 实验单位与样本量

实验单位分为两层。**Campaign** 为系统范围的自主扫描任务，一次 campaign 对应一个被测配置在一个业务应用上的完整发现与测试过程。**Episode** 为固定场景的一次独立任务运行，可覆盖一个独立实验组中的多个位置，分别保存位置判定及组级依赖关系。

开发集用于预算校准与流程验证，每配置每题 3 次重复，不计入正式成绩。正式实验每配置每题 5 次独立重复。开发集与隐藏测试集按逻辑目标及共享故障注入组或修复组切分，避免同组题目泄露。开发集目标为每应用 3 个独立组，隐藏测试集目标每合格应用 12 个独立组（6 个阳性、6 个阴性），资格化后按机制类型分层不放回抽样。若实际合格组数不足目标，按已冻结的全部合格组纳入，报告实际样本量与覆盖缺口，不复制题目凑数，不得将推断继承（inferred）位置拆为独立组。

发现任务（任务一自主阶段）在测试集全部 Ground Truth 范围内评价。标准执行任务（任务二）与标准诊断任务（任务三）使用抽取的题目子集。标准题集从资格化 GT 的阳性、阴性独立实验组中按机制分层不放回抽样，参考场景由构建侧独立验证，在测试前冻结并对各配置统一分配，选择独立于所有被测智能体的输出与尝试。修复组每应用最多选择 4 个，经修复契约可验证性筛选后冻结。这些组覆盖的阳性位置构成G_{fix}，统一初始状态与验收契约构成标准修复题集T_{fix}。标准任务按T_{fix}分配 5 次试验，集合选择独立于被测智能体的输出与尝试。

7.4 预算与窗口

表 3 预算配置方案（计划参数）

任务模式	时长上限	语义工具动作	主故障尝试	备注
自主 campaign	180 min	300	12 次，同逻辑风险≤2 次	首次注入前封存
标准执行	45 min	100	≤2 次	每 episode
标准诊断	20 min	50	只读	每 episode
标准修复	60 min	150	≤2 次修复提交，每次 1 次重放	每 episode
单次主故障生效期	≤20 min	-	-	完整观察依题目契约

语义工具动作按读取、观测、注入、恢复等能力计数，不按 API 调用包数制造形式公平。Token 上限在开发集中按最长上下文和成功参考过程校准后同轨冻结并记录，实验中不按智能体调整。绝对时间从任务分配时刻起计，清理兜底单独计时且不救分。自主模式首次注入前封存初始计划。

若某规则的健康谓词与基线或清理时限超出默认总预算，在开发阶段统一登记为长窗口组，或在测试前统一延长该题目所有配置的预算，不得在测试时按模型单独放宽。超出本版执行器能力的规则不资格化。

7.5 扰动与配对

标准任务二采用同题同种子无扰动与有扰动配对设计。八类额外扰动（目标漂移、配额缩减、遥测异常、指标缺口、主故障强度偏差、基线漂移、安全阈值压力、清理延迟）在应用与机制类型间平衡分配，每题仅施加一种扰动。扰动以语义事件触发，不要求不同智能体在第 N 次同名调用时触发。信息结构变换（保语义）与运行约束改变分别分组标注。

系统配置和执行顺序按应用与重复次数形成区组并随机化，无扰动与有扰动顺序交替平衡。每次 episode 独立初始化，使用同一快照、状态及负载条件，验证故障残留清除、数据完整及健康窗口满足后再执行下一题，不在失败状态串联题目。

基线采集至少 3 个完整 60 秒业务窗口，阈值按每应用的服务契约与开发阶段负载资格化后冻结，不使用统一的 90 或 99 百分位数替代业务契约。健康机制观测窗口由 deadline、探针周期、退避策略或恢复契约决定，完整谓词满足后可提前停止。

7.6 失败与无效处理

智能体早期失败（如规划阶段超时或拒绝任务）保留在总分母中。平台 fixture 失效（如执行器故障、集群资源不足）标记为 CASE_INVALID，不计入成败，按同种子补跑一次，仍失效则整个配对隔离并报告数量与原因，不得仅删除不利的单侧数据。智能体操作导致题目环境损坏仍判定为该智能体失败。

平台未能成功施加扰动标记为该扰动条件无效，按同一预注册规则补跑。被智能体早期失败阻断而未触发的扰动仍计入分配总体的失败，标注为未暴露，不补跑。运行预算耗尽后由 controller 清理并结束 episode，不无限补充尝试。

7.7 独立评价与一致性

Ground Truth 构建者、被测智能体及 evaluator 相互独立。参考运行为每个规则执行正负对照各 3 次以支持判定冻结，结论不稳定的位置保持未决状态。人工评价采用两名评价者对全部诊断与修复争议样本及分层抽取的 20%无争议样本双重评价，由第三方裁决者解决分歧，报告一致率与 Cohen's kappa 系数。一致性验证是判定流程可靠性的证据，不作为判定正确性的充分证明。

7.8 统计分析

RQ1 分轨报告核心闭环能力、联合定位场景能力及标准任务成功率，附 95%置信区间。**RQ2** 报告标准输入各阶段能力差异与自主模式的漏斗分布，两者样本分开。**RQ3** 报告同题同种子配对的成功率差、扰动实际暴露率及处理率。

所有比例指标报告分子、分母及 95%置信区间。自主模式以完整 campaign 为运行观测单位：在每个应用内，将同一重复编号下各配置的配对 campaign 作为重采样块，保留同一 campaign 的全部位置与完整输出向量。标准 episode 按独立故障注入组或修复组进行 cluster bootstrap，保留组内全部 5 次重复、配置配对及无扰动/有扰动条件配对，位置继承不增加独立组数。两类重采样均执行 10000 次。主分析为配对成功率差及分布或时长的效果量；在开发阶段为每轨预指定一个参照配置，测试前冻结最多 3 个关键比较并应用 Holm 校正控制族错误率，不跨轨道混合排名。

通过资格化的应用作为固定分层，逐应用展示并计算等权宏平均。置信区间解释已测应用、题集和重复条件下的运行差异，不用于推断应用总体。$\text{pass@}5$与pass^5作为补充指标，不替代单次成功率的主分析。

8 实验结果与分析框架

结果按整体能力、标准阶段能力和扰动配对三类组织，各率同时报告分子、分母与不确定性。

RQ1 整体能力差异:表 4 按轨道 A(固定框架切换模型)与轨道 B(原生系统)分别报告整体能力指标,两轨道归因机制分开。轨道内配置间比较采用配对差异检验,报告宏平均联合 F1、核心自主完成率及分项目展示;两轨结果分别解释为固定 BladeAI 内的模型配置效果和完整原生系统效果。

表 4 整体能力指标(按轨道分列)

轨道	配置 ID	应用	有效 campaign	初始 jointF1	核心闭环率	总成本
A						
A						
B						
B						

RQ2 能力瓶颈阶段:表 5 呈现标准任务输入的固定分母阶段比较,与自主闭环漏斗传播并列分析。标准任务(统一项目资料、已验证场景、固定证据起点)隔离上游差异,使各阶段能力可在相同输入下比较;自主漏斗(发现定位→有效场景→执行验证→诊断→自主恢复，修复为扩展分支)展示累积传播效应,但下游样本因上游筛选产生偏差,不能将漏斗乘积解释为独立能力。主要失败阶段列记录最早失败环节分布,区分设计错误、执行失败、诊断缺陷及修复未完成。

表 5 标准阶段能力(固定输入分母)

配置	执行 n	执行成功率	诊断 n	诊断准确率	修复 n	修复成功率	主要失败阶段

RQ3 扰动影响:表 6 在固定有效同题集上估计无扰动与有扰动条件的配对成功率差。令 M 为有效分配对数，E 为额外扰动实际施加且被测智能体遭遇的次数，C 为其中满足预定识别、调整和恢复处理判据的次数，暴露率为 E/M，处理率为 C/E。处理成功与主任务成功分别记录；智能体在扰动触发前失败仍保留在 M 中，并记录未暴露原因。平台施加失败按第 7.6 节统一处理。信息结构变换作为保语义输入变体另行配对，运行约束变化单独标注。各配置的总资源消耗与成功数共同解释效率，防止少尝试或提前失败造成虚假的资源优势。

表 6 扰动配对实验（固定同题集）

扰动类型	有效配对 M	成功率差	暴露率 E/M	处理率 C/E
目标漂移				
配额缩减				
遥测异常				
指标缺口				
主故障强度偏差				
基线漂移				
安全阈值压力				
清理延迟				
保语义输入变体				

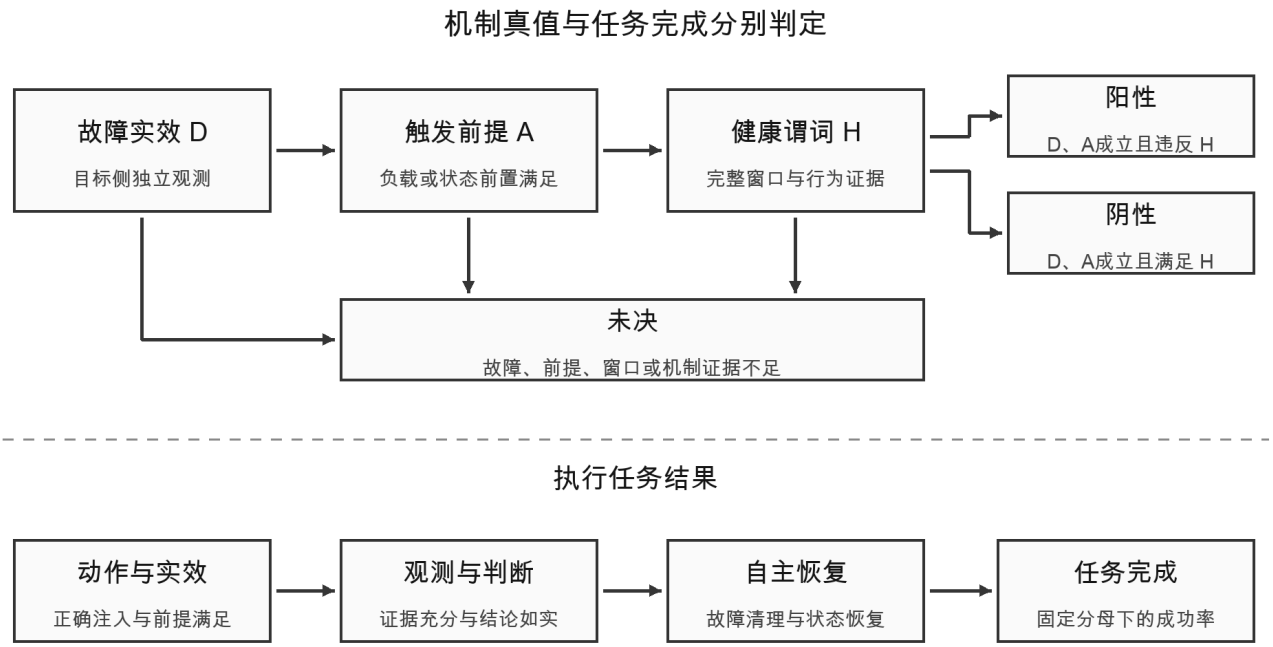


图 2 机制真值与执行任务的独立证据判定链

9 讨论与有效性威胁

构念有效性:本研究将韧性测试能力操作化为发现、设计、执行、诊断、修复五阶段及对应指标,其中场景三门(可执行、能触发、判据正确)与 D/A/H 三维 Oracle 分属设计质量与运行有效性不同层次。机制适用性判断依赖业务契约与系统特征,静态扫描枚举结合语义核查可识别显式保护对象,但无法证明覆盖完备——未显式配置的框架默认行为、上层包装隐式保护均可能导致 Ground Truth 遗漏,未决样本的存在反映此边界。健康谓词以规则所需的探针、状态、调用及数据证据操作化，业务 SLO 影响另行观测,调用方 deadline 与下游后台取消、API ACK 与实际状态恢复需分别观察,观测窗口依 deadline/探针/退避策略确定,不采用固定时长判断。

内部有效性:固定条件设计检验机制有效性,不搜索参数失效边界或阈值最优性;离散预注册变体集合验证参数敏感性,但受执行器能力与测试副本范围约束。8 类主故障对不同机制触发条件不等价,共享下游依赖、相同 ConfigMap 引用不构成继承保护逻辑的充分条件,需验证覆盖路径、前提一致且无位置级 override。共享 Ground Truth 位置导致样本相关性,统计分析需按项目/独立实验组处理,当前原型应用数量有限,外推需谨慎。独立 evaluator 依据白名单证据裁决,reference 判断涉及人工复核,但 GT 构建器与被测 agent 分离,动态 Oracle 不依赖模型自证。

外部有效性:候选配置覆盖固定框架多模型与原生系统,但各配置资格需冻结 ID、版本、工具权限后核实,公开材料可能污染预训练知识。随机服务行为(负载调度、网络抖动)可能导致相同场景不同轮次

D/A 状态差异,重复实验与 paired 设计部分缓解此问题。受允许测试副本限制,节点故障域隔离等分布式故障类型实际可操作范围有限。

结论有效性:本研究贡献为评测方法、构建协议及可执行框架,不宣称 Ground Truth 完备或最优参数配置。机制适用性判断依赖领域知识,扰动设计固定分母比较而非开放搜索,方法范围限定于规定故障类型与预校准参数组合。独立组数和重复次数决定估计精度，置信区间与分项目结果共同界定结论可支持的范围。

10 相关工作

AIOpsLab [1] 提供故障、负载、遥测与交互的整体框架，涵盖检测、定位、RCA 与缓解四阶段任务，支持多解终态评价。该工作证明了交互式与阶段评价的可行性，本文在此基础上专注于主动风险探索与场景设计能力的评测，并引入机制约束真值及跨原生系统的公平比较。

ITBench [2] 系统化 IT 自动化任务，SRE 诊断与缓解任务具有预定真值、终态验证与重复运行支持。本文借鉴其标准化任务设计思路，进一步区分自主闭环与标准输入模式，提供阶段标准输入以隔离上游差异，支持能力瓶颈分析。

RCAEval [4] 提供故障注入后的多源遥测与根因注释，支持服务与指标级 RCA 评价。本文不同于事后诊断任务，聚焦主动发现、场景设计与执行恢复的完整闭环，真值构建需包含场景有效性判据与执行 Oracle。

ReliabilityBench [5] 采用 pass^k 可靠性指标、保语义输入变换、受控工具失败与终态等价判据。本文采纳这些概念并扩展为双层扰动记录：区分被测业务主故障与智能体运行扰动，分别记录暴露率、处理率及恢复证据，避免将扰动未触发或处理成功与主任务失败混淆。

ChaosEater [3] 实现了假设生成、场景设计、故障注入观测、分析、配置改进与重放的全自动混沌工程闭环。本文定位为面向多种智能体的比较基准，提供机制约束独立真值、两类输入协议与固定分母设计，支持跨原生系统的能力差异分析。

软件修复与可靠性评价　SWE-bench [11] 提供 issue 驱动的代码修改与测试评估，FAIL_TO_PASS 与 PASS_TO_PASS 思路可借鉴修复验证与回归检测。τ-bench [10] 使用终态数据库对照与 pass^k 全成功率评价工具交互可靠性。本文的修复任务需结合机制健康谓词与业务状态证据，验证器按逻辑目标重绑定，接受合理冗余但拒绝停止负载或重写验收标准的伪修复。

方法学规范　ACM SIGSOFT 实证标准[12]要求明确被测质量、指标定义、测量方法、工作负载与样本选择、实验设置复现、重复次数、构念效度与原始结果透明。本文遵循这些规范，提供可执行的实验设计参数、冻结协议与失效处理规则。

11 结论

本文提出 BenchmarkFactory，一个面向智能体韧性测试闭环的机制驱动评测基准。通过独立真值构建、统一任务协议与可执行实验设计，支持比较不同智能体在发现、设计、执行、诊断与修复全流程的能力差异，识别能力瓶颈阶段，并评估信息变化与运行扰动对执行稳定性的影响。该框架适用于跨原生系统与模型配置的公平比较，为智能体主动测试能力的系统化评价提供了方法学基础。

参考文献

[1] Yinfang Chen, Manish Shetty, Gagan Somashekar, Minghua Ma, Yogesh Simmhan, Jonathan Mace, Chetan Bansal, Rujia Wang, Saravan Rajmohan. AIOpsLab: A Holistic Framework to Evaluate AI Agents for Enabling Autonomous Clouds. *Proceedings of Machine Learning and Systems*, 7, 2025. 出版来源

[2] Saurabh Jha, Rohan R. Arora, Yuji Watanabe, et al. ITBench: Evaluating AI Agents across Diverse Real-World IT Automation Tasks. *Proceedings of the 42nd International Conference on Machine Learning*, PMLR 267, 27134–27197, 2025. 出版来源

[3] Daisuke Kikuta, Hiroki Ikeuchi, Kengo Tajiri. LLM-Powered Fully Automated Chaos Engineering: Towards Enabling Anyone to Build Resilient Software Systems at Low Cost. *2025 40th IEEE/ACM International Conference on Automated Software Engineering*, New Ideas and Emerging Results Track, 2025. doi:10.1109/ASE63991.2025.00331

[4] Luan Pham, Hongyu Zhang, Huong Ha, Flora Salim, Xiuzhen Zhang. RCAEval: A Benchmark for Root Cause Analysis of Microservice Systems with Telemetry Data. *Companion Proceedings of the ACM Web Conference 2025*, 2025. doi:10.1145/3701716.3715290

[5] Aayush Gupta. ReliabilityBench: Evaluating LLM Agent Reliability Under Production-Like Stress Conditions. arXiv:2601.06112v1, 2026. doi:10.48550/arXiv.2601.06112

[6] Bogdan A. Stoica, Utsav Sethi, Yiming Su, Cyrus Zhou, Shan Lu, Jonathan Mace, Madanlal Musuvathi, Suman Nath. If At First You Don't Succeed, Try, Try, Again...? Insights and LLM-informed Tooling for Detecting Retry Bugs in Software Systems. *Proceedings of the 30th ACM Symposium on Operating Systems Principles*, 2024. doi:10.1145/3694715.3695971

[7] Utsav Sethi, Haochen Pan, Shan Lu, Madanlal Musuvathi, Suman Nath. Cancellation in Systems: An Empirical Study of Task Cancellation Patterns and Failures. *16th USENIX Symposium on Operating Systems Design and Implementation*, 127–141, 2022. 出版来源

[8] Ding Yuan, Yu Luo, Xin Zhuang, Guilherme Renna Rodrigues, Xu Zhao, Yongle Zhang, Pranay U. Jain, Michael Stumm. Simple Testing Can Prevent Most Critical Failures: An Analysis of Production Failures in Distributed Data-Intensive Systems. *11th USENIX Symposium on Operating Systems Design and Implementation*, 249–265, 2014. 出版来源

[9] André van Hoorn, Aldeida Aleti, Thomas F. Düllmann, Teerat Pitakrat. ORCAS: Efficient Resilience Benchmarking of Microservice Architectures. *29th IEEE International Symposium on Software Reliability Engineering Workshops*, 146–147, 2018. doi:10.1109/ISSREW.2018.00-10

[10] Shunyu Yao, Noah Shinn, Pedram Razavi, Karthik Narasimhan. τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains. arXiv:2406.12045, 2024. doi:10.48550/arXiv.2406.12045

[11] Carlos E. Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press, Karthik Narasimhan. SWE-bench: Can Language Models Resolve Real-World GitHub Issues? *International Conference on Learning Representations*, 2024. doi:10.48550/arXiv.2310.06770

[12] ACM SIGSOFT. Empirical Standards for Software Engineering Research: Benchmarking of Software Systems. 在线方法学标准，访问 2026-10-20. 出版来源

附录 A 规则与重放契约示例

规则：调用方 **deadline** 绑定。 适用于存在同步 RPC 调用且业务契约要求有界等待的逻辑调用位置。构建者检查调用点、客户端默认行为及上层配置的实际覆盖，形成有效 deadline 缺失或失效的候选。固定故障为目标 RPC 请求挂起；触发前提为调用方在该状态下发起目标请求。健康谓词 H 是调用方在冻结时限内终止等待并释放契约要求的调用资源，观测窗口覆盖有效 deadline 与终止验证所需时间。恢复要求挂起故障消除、正常请求与业务状态满足冻结契约。

修复可绑定有效的请求 deadline，或采用经验证覆盖该调用路径的客户端超时；验收按逻辑目标重新绑定，重放同一故障验证 H，同时检验正常业务、数据保留和资源预算，接受满足契约的多种方案。

公开执行题给出逻辑调用、挂起场景和有界等待的观测目标，隐藏阳性、阴性和根因。标准诊断题提供统一 trace 片段、状态证据及同等只读追查范围，要求输出薄弱组件、机制、原因和证据链。调用方终止等待与下游后台任务取消分别判定；故障前写入 ACK 是持久化类规则可采用的触发前提，两者各按自身规则建立有效试验。